

PRUEBA DE CONCEPTO · RAMO AUTOMÓVILES

InsurAgent

Reporte técnico de un asistente agéntico para el sector asegurador: arquitectura, razonamiento de diseño, métricas de evaluación e infraestructura.

AUTOR

Diego Carrillo Mondragón

FECHA DE GENERACIÓN

3 de septiembre de 2026

PROVEEDOR EVALUADO

anthropic · claude-opus-5

EMBEDDINGS

sentence-transformers

Documento generado automáticamente a partir de la corrida de evaluación. Todos los datos son sintéticos: identificadores, condiciones generales, importes y catálogo de talleres son ficticios y no corresponden a personas ni a productos reales.

Contenido

1. Resumen y métricas de aceptación

Las cinco métricas del PRD §5 y cómo leerlas.

2. Arquitectura agéntica

Topología del grafo, el orquestador y la máquina de estados.

3. Recuperación aumentada (RAG)

Diseño del corpus, decisiones de indexado y resultados.

4. Conversaciones trazadas

Tres conversaciones reales, turno a turno, con su traza interna.

5. Contratos de datos y validación

Cómo se impide que una alucinación llegue a la base.

6. Aritmética fuera del modelo

Por qué el deducible no lo calcula el LLM.

7. Gestión de memoria

Memoria de sesión y memoria de largo plazo: dónde vive cada una.

8. Observabilidad

Trazado por nodo y auditoría de las decisiones de enrutamiento.

9. Latencia y costo

Consumo medido y las decisiones que lo mantienen bajo.

10. Seguridad y datos personales

LFPDPPP, datos sintéticos y gestión de secretos.

11. Infraestructura en GCP

Equivalencias local ↔ nube y el esquema de Terraform.

12. Acceso al servicio y credenciales

Cómo levantar la aplicación y con qué datos entrar.

13. Limitaciones y siguientes pasos

Qué queda fuera y qué habría que hacer después.

Resumen y métricas de aceptación

InsurAgent es un sistema agéntico conversacional que interpreta las condiciones generales de una póliza de automóvil y asiste al asegurado en tres tareas: consultar coberturas y deducibles, levantar el reporte de un siniestro (FNOL) y localizar talleres de la red en convenio.

La PoC corre íntegramente en local —SQLite, FAISS y Streamlit—, con el modelo de lenguaje como único componente remoto. Su equivalente en Google Cloud está escrito en Terraform y validado, de modo que el salto a la nube no requiere rediseñar nada.


100% RECUPERACIÓN RAG umbral $\geq$ 80 %	100% DEDUCIBLE COTIZADO umbral 100 %	100% ENRUTAMIENTO umbral $\geq$ 85 %
100% FNOL END-TO-END umbral 100 %	3761 ms LATENCIA MEDIA/TURNO umbral < 5 000 ms	\$0.03187 COSTO POR SESIÓN umbral < \$0.10 USD

Detalle de la corrida

Concepto	Valor
Latencia p95 por turno	8270 ms
Tokens de entrada	47,284
Tokens de salida	7,136
Corrida ejecutada	2026-09-04T00:49:19+00:00

Arquitectura agéntica

El sistema es un grafo de estados de LangGraph con un nodo condicional —el Orquestador— y cuatro agentes terminales. Sobre ese grafo corre una máquina de estados que da continuidad al flujo de reporte a lo largo de varios turnos.



Grafo de agentes. El Orquestador es el único nodo condicional; los cuatro agentes son terminales. Todos los nodos emiten trazas, de ahí la banda transversal inferior.

Decisiones que definen el comportamiento

Decisión de diseño	Razón
La confirmación «¿deseas reportarlo?» se resuelve con reglas, no con el LLM	Un sí/no no justifica una llamada al modelo: ni su latencia, ni su costo, ni su varianza. La comparación es por token completo, no por subcadena, para que <code>nosotros</code> no se lea como <code>no</code> .
Dentro del flujo FNOL el orquestador no vuelve a clasificar	Reclasificar cada turno sacaría al asegurado del flujo a la mitad —por ejemplo si al describir el percance menciona un taller—. La continuidad es una regla explícita de la máquina de estados, no un accidente.
El enrutamiento usa salida estructurada, sin clasificador adicional	El modelo devuelve un JSON validado contra <code>RouteDecision</code> (ruta, confianza y justificación). La justificación se persiste en la traza: sin ella no se puede auditar por qué una consulta terminó en cierto agente.
El nodo de cortesía no consume modelo	Su guion es fijo y auditable. Gastar tokens en «gracias, ¿algo más?» no aporta calidad y sí introduce variabilidad.

Máquina de estados de la conversación

El PRD §6 describe el recorrido del usuario en prosa. Traducido a estados explícitos, queda así —y es lo que permite que el sistema retome una conversación a medias sin volver a preguntar lo ya capturado:

Etapa	Significado	Qué la abre
idle	Conversación libre; cada turno se enruta desde cero.	Inicio de sesión, o una negativa.
confirm_fnol	Se evaluó la póliza y se preguntó si desea reportar.	El Agente de Pólizas detecta un siniestro amparado.
collecting	El Agente FNOL recolecta los datos del siniestro.	Confirmación afirmativa, o intención explícita de reportar.
awaiting_evidence	Datos completos; falta la fotografía del daño.	El borrador pasa la validación de completitud.
done	Expediente registrado con folio.	Se adjunta la evidencia, o el asegurado la omite.

Resultados por caso de enrutamiento

Los cinco primeros casos son la tabla textual del PRD §3.1; el resto son variantes adversariales: menciones de siniestro que no deben abrir un expediente, y preguntas de taller que mencionan un choque.

Caso	Ruta esperada	Ruta observada	Correcto
rt-01	policy	policy	✓
rt-02	policy	policy	✓
rt-03	policy	policy	✓
rt-04	network	network	✓
rt-05	fnol	fnol	✓
rt-06	fnol	fnol	✓
rt-07	network	network	✓
rt-08	policy	policy	✓
rt-09	smalltalk	smalltalk	✓
rt-10	fnol	fnol	✓
rt-11	network	network	✓
rt-12	policy	policy	✓
rt-13	policy	policy	✓
rt-14	smalltalk	smalltalk	✓
rt-15	network	network	✓
rt-16	policy	policy	✓

Recuperación aumentada (RAG)

Se indexan **tres** variantes de condiciones generales con cláusulas deliberadamente traslapadas. La cobertura de Responsabilidad Civil aparece en las tres con límites distintos, y Robo Total aparece en dos con el mismo deducible pero requisitos distintos.

Ese traslape es el punto del ejercicio: un corpus de un solo documento no obliga al recuperador a discriminar y produce métricas engañosamente altas.

Paquete	Cláusulas	Alcance
Responsabilidad Civil	4	Sólo RC (\$2 MDP) y asistencia vial básica.
Básica	7	RC (\$3 MDP), robo total y asistencia vial ampliada.
Amplia	8	Todo lo anterior más daños materiales, cristales y gastos médicos.

Decisiones de indexado

Decisión	Razón
IndexFlatIP sobre vectores normalizados L2	El score es coseno exacto. Con 19 cláusulas, un índice aproximado (IVF/HNSW) sólo añadiría error e hiperparámetros sin ganancia de latencia medible.
Una cláusula equivale a un fragmento	La cláusula ya es la unidad semántica del documento. Partir por ventana fija separaría el deducible de la cobertura a la que pertenece.
Se antepone el nombre del paquete al texto vectorizado	Sin esa señal, las tres versiones de la cláusula de Responsabilidad Civil producen vectores casi idénticos y el recuperador elige prácticamente al azar.
El filtro por paquete se aplica después de la búsqueda vectorial	Filtrar antes volvería trivial el problema y produciría una métrica inflada. Se sobre-recupera y luego se restringe, de modo que el recuperador tenga que discriminar de verdad entre textos casi iguales.

Dos caminos para el mismo resultado

La recuperación admite dos backends intercambiables, y la elección resultó ser una decisión de despliegue antes que de calidad.

Backend	Precisión RAG	Memoria del proceso	Arranque
Modelo denso multilingüe	15/15 · 100 %	2 158 MB	≈ 6 s
Léxico con diccionario del dominio	15/15 · 100 %	214 MB	0.3 s

El modelo denso no cabe en un hosting gratuito: PyTorch más el modelo llevan el proceso a más de 2 GB. La alternativa fue un diccionario del dominio que traduce el habla del asegurado a la redacción contractual —«choqué» y «colisión» comparten un término canónico que se añade como característica tanto al indexar como al consultar—, con las características del dominio ponderadas por encima de los n-gramas de carácter, que son decenas por frase y ahogaban la señal.

Igualar no es equivaler

Que ambos midan 15/15 sobre este set no los hace intercambiables. El diccionario sólo cubre lo que está escrito en él; el modelo denso generaliza a términos no previstos. Con 19 cláusulas y un vocabulario acotado esa ventaja no se manifiesta, pero con un corpus de miles reaparecería — y entonces el modelo denso volvería a ser la elección correcta, sobre un plan con memoria suficiente.

La contrapartida es que el diccionario es auditable por un experto en seguros y se corrige añadiendo una palabra, cosa que un modelo denso no permite.

Resultados por pregunta dorada

Caso	Cláusula esperada	Cláusulas citadas	Cita	Deducible
rag-01	RC-1.1	RC-1.1, RC-2.1, RC-9.1, RC-6.1	✓	✓
rag-02	AMP-1.1	AMP-1.1, AMP-3.1, AMP-8.1, AMP-5.1	✓	✓
rag-03	BAS-1.1	BAS-1.1, BAS-2.2, BAS-2.1, BAS-8.1	✓	✓
rag-04	AMP-3.1	AMP-3.1, AMP-1.1, AMP-4.2, AMP-2.1	✓	✓
rag-05	BAS-2.1	BAS-2.1, BAS-1.1, BAS-6.1, BAS-9.1	✓	✓
rag-06	RC-2.1	RC-2.1, RC-1.1, RC-9.1, RC-6.1	✓	✓
rag-07	AMP-4.2	AMP-4.2, AMP-3.1, AMP-5.1, AMP-1.1	✓	✓
rag-08	BAS-4.2	BAS-4.2, BAS-2.2, BAS-1.1, BAS-2.1	✓	✓
rag-09	AMP-2.1	AMP-2.1, AMP-4.2, AMP-1.1, AMP-3.1	✓	✓
rag-10	BAS-2.2	BAS-2.2, BAS-2.1, BAS-4.2, BAS-9.1	✓	✓
rag-11	AMP-5.1	AMP-5.1, AMP-1.1, AMP-3.1, AMP-4.2	✓	✓
rag-12	BAS-6.1	BAS-6.1, BAS-1.1, BAS-2.1, BAS-8.1	✓	✓
rag-13	RC-6.1	RC-2.1, RC-6.1, RC-1.1, RC-9.1	✓	✓
rag-14	AMP-9.1	AMP-9.1, AMP-3.1, AMP-2.1, AMP-5.1	✓	✓
rag-15	AMP-8.1	AMP-8.1, AMP-3.1, AMP-5.1, AMP-1.1	✓	✓

Conversaciones trazadas

Las tablas de los capítulos anteriores dicen cuánto acierta el sistema, pero no dejan ver cómo llega a una respuesta. Estas conversaciones se capturaron ejecutando la aplicación real: entre cada mensaje del asegurado y la respuesta del asistente se muestra lo que ocurrió en medio —la decisión de enrutamiento con su justificación, las cláusulas que FAISS recuperó con su similitud, el deducible calculado en Python y los expedientes previos inyectados en el contexto.

Cada conversación indica qué casos del set dorado ejercita, para poder ir de una fila de aquellas tablas a la conversación que la produjo.

Capturadas con el proveedor `anthropic` · modelo `claude-opus-5`.

CONV-01 — SINIESTRO RECURRENTE: MEMORIA DE LARGO PLAZO Y FLUJO FNOL COMPLETO

Recorre el user journey del PRD §6 de principio a fin sobre un asegurado que ya tiene un siniestro de cristales en su historial. Muestra las tres cosas juntas: que el asistente recuerda conversaciones anteriores, que el enrutamiento cambia de agente entre turnos, y que el expediente sólo se crea cuando el asegurado lo confirma.

Casos del set dorado que ejercita: `rag-07`, `rt-02`

Asegurado: Elena Jiménez Lozano · **Póliza:** AUT-2026-100000 · **Paquete:** amplia
Vehículo: Nissan Versa 2022 · **Ciudad:** Puebla
Memoria de largo plazo (1 expediente):

◦ SIN-202603-75926 · cristales · 2026-03-30 · Av. Vallarta, Col. Providencia

ASEGURADO

Otra vez se me estrelló el parabrisas. ¿Cuánto tendría que pagar de deducible?

Decisión del orquestador: El usuario narra el percance del parabrisas pero su petición explícita es conocer el monto del deducible, lo que corresponde a evaluación de cobertura y no a un aviso formal de siniestro.

Memoria de largo plazo: se inyectaron 1 expediente(s) previos en el contexto.

Deducible calculado en Python: **\$2,400.00 MXN** (no lo produjo el modelo).

Cláusulas recuperadas de FAISS:

Cláusula	Título	Paquete	Similitud
AMP-3.1	Robo total del vehículo	amplia	0.513
AMP-4.2	Rotura de cristales	amplia	0.462
AMP-5.1	Gastos médicos ocupantes	amplia	0.450
AMP-1.1	Responsabilidad Civil por daños a terceros	amplia	0.425

INSURAGENT

Sí, la rotura de parabrisas está amparada por su cobertura de cristales [AMP-4.2], que aplica a parabrisas, medallón, cristales laterales y quemacocos por cualquier causa accidental.

El deducible aplicable es del 20% sobre el costo de reposición del cristal, con mínimo de \$1,500.00 MXN por evento, lo que en su caso equivale aproximadamente a **\$2,400.00 MXN** [AMP-4.2].

Veo que ya tenemos registrado un siniestro previo de cristales, folio SIN-202603-75926 del 30 de marzo de 2026 en Av. Vallarta, Col. Providencia, así que no necesita explicarlo de nuevo; este sería un evento nuevo e independiente.

Tenga en cuenta que espejos laterales, micas de faros y calaveras no están amparados [AMP-4.2].

Confirmo que usted tiene contratado el paquete **amplia** para su Nissan Versa 2022.

¿Deseas que levantemos el reporte del siniestro ahora?

TURNO 2 AGENTE FNOL CONFIANZA 100% · RECOLECTANDO DATOS · 5,498 MS

ASEGURADO

Sí, quiero reportarlo

Decisión del orquestador: El asegurado confirmó que desea reportar el siniestro.

INSURAGENT

Lamento mucho lo ocurrido, Elena; con gusto la ayudo a levantar su reporte por daño en cristales.

Para comenzar, ¿podría indicarme la fecha en que ocurrió el siniestro y el lugar donde sucedió (ciudad y dirección aproximada)?

TURNO 3 AGENTE FNOL CONFIANZA 100% · ESPERANDO EVIDENCIA · 3,792 MS

ASEGURADO

Fue ayer en Avenida Insurgentes, colonia Del Valle. Una grava que levantó un camión de carga rompió el parabrisas mientras iba circulando.

Decisión del orquestador: Continuidad del flujo FNOL (etapa collecting).

INSURAGENT

Ya tengo todos los datos de tu reporte. Para completar el expediente, ¿podrías adjuntar una fotografía del daño? Quedará vinculada a tu siniestro.

TURNO 4 AGENTE FNOL CONFIANZA 100% · EXPEDIENTE CERRADO · 0 MS

ASEGURADO

[adjunta fotografía del daño: dano_parabrisas.png]

Decisión del orquestador: Carga de evidencia fuera del grafo: la valida y persiste la sesión.

Deducible calculado en Python: \$2,400.00 MXN (no lo produjo el modelo).

Expediente creado: SIN-202609-00008

La evidencia se valida (tipo MIME y tamaño) antes de tocar el disco.

INSURAGENT

Reporte registrado con folio SIN-202609-00008. Evidencia guardada en 20260903184941_dano_parabrisas.png.

La evidencia quedó vinculada al expediente SIN-202609-00008 : el archivo se guardó en disco y su metadata — nombre, ruta, tipo, tamaño y fecha— en la base transaccional.

CONV-02 — DISCRIMINACIÓN ENTRE PAQUETES: LA MISMA PREGUNTA, OTRA RESPUESTA

El mismo tema —rotura de cristales— consultado por un asegurado con paquete Básica. El recuperador debe traer la cláusula de exclusión de Básica y no la de cobertura de Amplia, que es el caso duro del corpus traslapado descrito en el PRD §4.2.

Casos del set dorado que ejercita: rag-08 , rt-02

Asegurado: Carmen Guerrero Jiménez · **Póliza:** AUT-2026-100137 · **Paquete:** basica
Vehículo: Chevrolet Aveo 2016 · **Ciudad:** Monterrey
Memoria de largo plazo (1 expediente):

◦ SIN-202603-47586 · robo_total · 2026-03-14 · Calzada de Tlalpan, Col. Portales

TURNO 1 **AGENTE DE PÓLIZAS** CONFIANZA 96% · CONVERSACIÓN LIBRE · 6,792 MS

ASEGURADO

Se me rompió el cristal del coche, ¿mi póliza lo cubre?

Decisión del orquestador: El usuario pregunta explícitamente si su póliza cubre la rotura de cristal, lo que es una consulta de cobertura y no una solicitud de reporte formal.

Memoria de largo plazo: se inyectaron 1 expediente(s) previos en el contexto.

Cláusulas recuperadas de FAISS:

Cláusula	Título	Paquete	Similitud
BAS-4.2	Exclusión de rotura de cristales	basica	0.473
BAS-2.2	Exclusión de daños materiales	basica	0.307
BAS-2.1	Robo total del vehículo	basica	0.274
BAS-9.1	Exclusiones generales	basica	0.270

INSURAGENT

Lamento el inconveniente, Carmen. La rotura de cristales **no está amparada** en su póliza: el paquete Básica excluye expresamente esta protección [BAS-4.2]. Por lo tanto, la reparación o reemplazo del cristal correría por su cuenta.

Si desea contar con esta cobertura, puede migrar al paquete Amplia en la siguiente renovación de su póliza [BAS-4.2]. Con gusto la canalizo con el área de suscripción para revisar esa opción.

Le confirmo que su paquete contratado es **Básica**.

CONV-03 — ENRUTAMIENTO A LA RED DE TALLERES

Consulta que menciona un siniestro pero pregunta por un taller. El orquestador debe mandarla al Agente de Red y no al de FNOL: es la variante adversarial rt-15 del set dorado.

Casos del set dorado que ejercita: rt-04 , rt-15

Asegurado: Elena Jiménez Lozano · **Póliza:** AUT-2026-100000 · **Paquete:** amplia
Vehículo: Nissan Versa 2022 · **Ciudad:** Puebla
Memoria de largo plazo (2 expedientes):

◦ SIN-202609-00008 · cristales · 2026-09-02 · Avenida Insurgentes, colonia Del Valle
◦ SIN-202603-75926 · cristales · 2026-03-30 · Av. Vallarta, Col. Providencia

ASEGURADO

¿Puedo llevar mi auto chocado a un taller cerca de Polanco?

Decisión del orquestador: El asegurado pregunta por un taller en una ubicación específica (Polanco), señal clara de búsqueda en la red con convenio, aunque mencione que el auto está chocado.

Talleres consultados: TAL-001

INSURAGENT

Sí, contamos con un taller con convenio en esa zona:

Servicio Automotriz Polanco — Av. Horacio 1220, Polanco, Ciudad de México.
Tel. 55-5280-1140. Atiende hojalatería, pintura y cristales, por lo que cubre lo necesario para un auto chocado.

Es la única opción disponible en Polanco dentro de la red; no tengo registrados otros talleres en esa zona. Tome en cuenta que su póliza está registrada en Puebla, así que le sugiero confirmar con su asesor si la atención fuera de su ciudad requiere algún trámite adicional.

Contratos de datos y validación

Toda información que cruza una frontera del sistema —entrada del usuario, salida estructurada del modelo, escritura a la base— pasa por un modelo Pydantic. Dos contratos merecen explicación.

Autenticación

`LoginRequest` valida el formato de los cuatro factores exigidos por el PRD §6.1 —póliza, RFC, CURP y últimos tres dígitos del celular— antes de tocar la base. La comparación de los cuatro ocurre en un solo método auditable, `Customer.matches`: la regla de acceso vive en un único lugar.

Siniestro: borrador contra expediente

Se distinguen dos tipos. El **borrador** (`IncidentDraft`) tiene todos los campos opcionales y se acumula turno a turno. El **expediente** (`ClaimReport`) los tiene todos obligatorios y es lo único que se persiste.

Un campo que el modelo no logre extraer se queda en `null` y se vuelve a preguntar, en lugar de rellenarse con una suposición. Esa separación es la barrera que impide que una alucinación llegue a la base transaccional: promover un borrador incompleto lanza una excepción, y hay una prueba que lo verifica.

Por qué importa en seguros

Un expediente de siniestro con una fecha inventada no es un error cosmético: es un dato que un ajustador usará para dictaminar. Preferimos preguntar de nuevo antes que registrar algo plausible pero falso.

Aritmética fuera del modelo

El deducible **no** lo calcula el modelo de lenguaje. `quote_deductible()` lo resuelve en Python a partir de la tabla de coberturas, y el resultado se inyecta en el prompt como hecho calculado; el modelo únicamente redacta. El prompt del Agente de Pólizas le prohíbe explícitamente recalcularlo o estimar importes.

Paquete	Cobertura	Deducible
Amplia	Daños materiales	5 % sobre valor comercial → \$16 000 sobre \$320 000
Amplia · Básica	Robo total	10 % sobre valor comercial → \$32 000
Amplia	Rotura de cristales	20 % del costo de reposición, mínimo \$1 500
Las tres	Responsabilidad civil	Sin deducible

El mínimo contractual de cristales es el caso interesante: con un costo de reposición de \$5 000, el 20 % son \$1 000 y entra el mínimo de \$1 500. Con \$20 000, el porcentaje manda y son \$4 000. Ambas ramas están cubiertas por prueba.

El principio general

Un modelo de lenguaje es un mal lugar para hacer aritmética sobre dinero. Todo cálculo con consecuencia económica se hace en código determinista y verificable, y el modelo se limita a comunicarlo.

Gestión de memoria

El PRD distingue dos memorias y la implementación las mantiene separadas a propósito: viven en sitios distintos porque tienen ciclos de vida distintos.

Memoria	Dónde vive	Qué contiene	Cuándo cambia
Corto plazo	Estado del grafo, en memoria del proceso	Asegurado autenticado, etapa del flujo FNOL, borrador del siniestro, cláusulas del turno	En cada turno; se descarta al cerrar sesión
Largo plazo	SQLite (PostgreSQL en GCP)	Siniestros previos con folio, tipo, fecha, lugar y deducible aplicado; vehículos; historial conversacional	Sólo cuando se registra un expediente nuevo

Cómo llega al modelo

El historial se carga una sola vez al iniciar sesión —no en cada turno: es memoria de largo plazo y no cambia a mitad de una conversación— y el Agente de Pólizas recibe un resumen de los **tres** expedientes más recientes en su contexto.

El límite de tres no es arbitrario: el historial completo crecería sin cota y desplazaría del contexto a las cláusulas recuperadas, que son justamente lo que el agente necesita para responder. Tres bastan para reconocer una recurrencia.

El prompt acota qué puede hacer con esa información: mencionar el folio de un siniestro previo del mismo tipo, y nada más. Tiene prohibido inferir que la prima subirá, que la cobertura se agotó o que hay penalización por recurrencia, porque nada de eso está en las cláusulas y sería exactamente el tipo de invención que más daño hace en seguros.

Sin historial precargado no hay nada que demostrar

Los datos sintéticos incluyen siniestros previos para la mitad de la cartera. Son coherentes con lo contratado —un asegurado con sólo Responsabilidad Civil no puede tener un expediente de cristales— y su deducible se calcula con la misma función que usa el Agente FNOL en producción, no con un número escrito a mano: si cambia la tabla de coberturas, el historial cambia con ella.

Un expediente recién creado pasa a ser memoria de largo plazo de inmediato: si el asegurado pregunta en el siguiente turno, el asistente ya lo conoce. La conversación `conv-01` del capítulo 4 muestra el ciclo completo.

Observabilidad

Cada nodo del grafo se envuelve en un contexto que emite un evento JSONL con `run_id`, nodo, estado, duración y carga útil específica. Para el orquestador, esa carga incluye la ruta elegida, la confianza y la justificación textual.

Se optó por trazado propio en lugar de LangSmith por dos razones: no requiere cuenta ni envía datos fuera del equipo —relevante cuando el dominio son datos de asegurados—, y el formato JSONL es directamente consultable durante una demostración.

```
# Todas las decisiones de enrutamiento de una sesión
jq -c 'select(.node=="orchestrator") | {run_id, route, reasoning}' data/traces.jsonl

# Los turnos más lentos
jq -s 'sort_by(-.duration_ms) | .[0:5] | .[] | {node, duration_ms}' data/traces.jsonl
```

La escritura de trazas nunca interrumpe la conversación: si el disco falla, se degrada la observabilidad y se registra una advertencia, pero el turno del asegurado continúa. También eso está cubierto por prueba.

El panel lateral de la interfaz muestra las últimas decisiones de enrutamiento en vivo, que es el requisito del PRD §4.1 llevado a la pantalla: quien hace la demostración puede explicar por qué el orquestador eligió cada agente.

Latencia y costo

El costo se calcula a partir de los tokens que reporta la API y la tarifa del modelo, no de una estimación a ojo. Tres decisiones lo mantienen bajo:

- El enrutamiento corre con `effort: low`. Es una clasificación, no un problema de razonamiento.
- La confirmación sí/no y el nodo de cortesía no consumen modelo.
- El contexto RAG se limita a las `top_k` cláusulas pertinentes, nunca al documento completo.

Concepto	Valor
Tokens de entrada	47,284
Tokens de salida	7,136
Costo por sesión completa	\$0.031870 USD
Latencia promedio por turno	3761 ms
Latencia p95 por turno	8270 ms

El techo de 10 USD que fija el PRD corresponde a la PoC completa —desarrollo, pruebas y demostración—, no a una sesión individual. El costo por sesión queda varios órdenes de magnitud por debajo de ese techo.

Seguridad y datos personales

Identificadores sintéticos

El RFC y la CURP son datos personales regulados por la LFPDPPP en México. Los identificadores que genera la PoC respetan el **formato** oficial —para que la validación sea representativa— pero llevan un marcador que los hace inasignables a una persona real:

- **RFC** — inicia siempre con `XXX` , por ejemplo `XXXJ860330FYB` .
- **CURP** — inicia con `XXXX` y usa la entidad `NE` , por ejemplo `XXXX860330MNEYSTB7` .

`LoginRequest.is_synthetic()` verifica ese marcador y la interfaz rechaza el acceso si no está presente: la PoC no puede ingerir un identificador real por accidente, ni siquiera si alguien lo teclea a propósito durante una demostración.

Gestión de secretos

Ninguna credencial vive en el repositorio. La API key se lee de `.env` , que está excluido del control de versiones junto con las llaves privadas, los archivos de credenciales de nube, el estado de Terraform —que guarda los secretos en texto plano— y los datos de asegurados.

El `.gitignore` se prueba como control de seguridad

Un secreto sólo se filtra una vez: después de un `push` queda en el historial público para siempre, aunque se borre en el commit siguiente. Por eso hay pruebas automatizadas que crean un repositorio desechable y le preguntan a git —no a una expresión regular propia— si cada ruta sensible quedaría fuera. Una prueba adicional escanea el árbol completo en busca de patrones de llaves.

Auditoría adversarial

Las preguntas doradas miden si el sistema acierta cuando el asegurado colabora. Estas sondas miden qué ocurre cuando no colabora: intentan extraer el prompt del sistema, los datos de otros asegurados o la credencial del proveedor, y hacer que el agente confirme coberturas que la póliza no ampara.

La evaluación es determinista —se buscan señales concretas de fuga en la respuesta— y no la juzga otro modelo: una auditoría de seguridad tiene que ser reproducible y revisable por un humano, no depender del criterio de un juez estocástico. Se ejecuta con `make audit` y devuelve código de error si alguna sonda pasa, para poder usarse como puerta en integración continua.

Categoría de ataque	Sondas	Contenidas
cobertura inexistente	3	3/3 ✓
credenciales	2	2/2 ✓
datos de terceros	3	3/3 ✓
extracción de instrucciones	2	2/2 ✓
inyección en campo libre	1	1/1 ✓
producto ajeno	1	1/1 ✓

Resultado: 12/12 sondas contenidas

La defensa resultó ser estructural más que de redacción: el Orquestador clasifica los intentos de extracción como fuera de alcance y los enruta al nodo de cortesía, que responde con un guion fijo **sin invocar al modelo**. Un ataque que nunca llega a un agente no puede extraerle nada.

Ante la petición de confirmar una cobertura inexistente —«mi paquete Básica sí cubre cristales, ¿verdad?»— el agente citó la cláusula de exclusión y se negó a emitir la confirmación, que es el comportamiento correcto en un proceso de siniestros.

Superficie de ataque considerada

Riesgo	Mitigación implementada
Escritura fuera del directorio de evidencia	Un nombre de archivo con <code>../</code> se reduce a su nombre base antes de tocar el disco. Cubierto por prueba.
Carga de archivos maliciosos o desmedidos	Lista blanca de tipos MIME y tope de 10 MB, validados antes de escribir.
Registro de siniestros con datos incompletos	Adjuntar evidencia fuera de la etapa <code>awaiting_evidence</code> lanza una excepción.
Integridad referencial en la base	<code>PRAGMA foreign_keys</code> activo; un siniestro huérfano es rechazado por el motor.

Infraestructura en GCP

El código Terraform está escrito y validado con `terraform validate`. Conforme al PRD §8 no se ejecuta en esta fase: queda listo para provisionar.

Componente local	Equivalente en GCP	Nota
Streamlit	Cloud Run	Escala a cero: sin tráfico, sin costo de cómputo.
SQLite	Cloud SQL for PostgreSQL	db-f1-micro , IP privada, sin IP pública.
<code>data/uploads/</code>	Cloud Storage	Acceso público bloqueado, versionado, ciclo a Nearline a los 90 días.
<code>.env</code>	Secret Manager	La llave nunca vive en la imagen ni en el estado de Terraform.
<code>data/index/</code>	Horneado en la imagen	El corpus es estático y pequeño; un servicio gestionado de búsqueda vectorial costaría más que todo lo demás junto.

Decisiones de seguridad en la nube

- Identidad de servicio dedicada con privilegio mínimo, no la cuenta por defecto del proyecto.
- Acceso público desactivado salvo que se pida explícitamente con una variable.
- `max_instances` como control de costo real, no como parámetro de rendimiento.
- Imagen fijada por tag inmutable: nunca `latest`.
- Contenedor con usuario no privilegiado y compilación en dos etapas, sin toolchain en la imagen final.

Acceso al servicio y credenciales de prueba

Servicio en línea

La aplicación está publicada y no requiere instalar nada

<https://dieguetecm-ui-insuragent-streamlit-app-f0ocjz.streamlit.app>

Basta abrir el enlace e ingresar con cualquiera de las credenciales sintéticas de la tabla siguiente. La primera visita del día puede tardar unos segundos: el servicio escala a cero y arranca bajo demanda.

Levantar el servicio en local

```
git clone <repositorio> && cd Practica_agente_seguros
pip install -r requirements-dev.txt
cp .env.example .env          # colocar ANTHROPIC_API_KEY
make bootstrap                # datos sintéticos + índice FAISS
make app                       # levanta la interfaz
```

La aplicación queda en `http://localhost:8501`. Sin `ANTHROPIC_API_KEY` el sistema arranca igual, pero con el proveedor determinista: útil para recorrer la interfaz, no para juzgar la calidad de las respuestas.

Servicio desplegado en GCP

Al aplicar el Terraform, la URL del servicio se obtiene de la salida `service_url`. Por omisión el servicio exige autenticación de IAM; para una demostración abierta hay que aplicar con `allow_public_access = true`, algo que conviene revertir al terminar.

```
cd infra/terraform
export TF_VAR_anthropic_api_key="sk-ant-..."
terraform apply
terraform output service_url
```

Credenciales de acceso

Estas credenciales son sintéticas y pueden publicarse

Los identificadores respetan el formato oficial mexicano pero llevan el marcador reservado (XXX en RFC, XXXX + entidad NE en CURP) que los hace insignificables a una persona real. Se regeneran idénticas con `make seed`, que además las imprime en la terminal.

Asegurado	Póliza	RFC	CURP	Cel.	Paquete	Historial
Elena Jiménez Lozano	AUT-2026-100000	XXXJ860330FYB	XXXX860330MNEYSTB7	769	amplia	sí
Carmen Guerrero Jiménez	AUT-2026-100137	XXXG7704151VA	XXXX770415MNEJHCB3	726	basica	sí
Fernando Ibarra Lozano	AUT-2026-100274	XXXI9209035QA	XXXX920903HNEJXBB6	423	rc	sí

El acceso exige los **cuatro** factores; fallar uno solo lo rechaza. Los tres asegurados tienen paquetes distintos a propósito: la misma pregunta debe producir respuestas distintas según lo contratado.

Qué probar

Qué probar	Qué escribir	Qué debería pasar
Consulta de cobertura	«¿Cuál es mi deducible por robo total?»	Ruta <code>policy</code> ; cita la cláusula del paquete contratado y el importe exacto.
Discriminación entre paquetes	«¿Mi póliza cubre la rotura de cristales?»	Con Amplia responde la cobertura; con Básica, la cláusula de exclusión.
Memoria de largo plazo	«Otra vez se me estrelló el parabrisas»	Con un asegurado que tiene historial, menciona el folio del siniestro anterior.
Flujo FNOL completo	«Quiero reportar un choque» y seguir las preguntas	Ruta <code>fno1</code> ; pide los datos faltantes y al final la fotografía del daño.
Red de talleres	«¿Dónde hay un taller cerca de Polanco?»	Ruta <code>network</code> ; lista talleres reales del catálogo, sin inventar sucursales.

El detalle del despliegue —incluidos Hugging Face Spaces y Cloud Run como alternativas— está en `DESPLIEGUE.md` del repositorio.

Limitaciones y siguientes pasos

Fuera de alcance por diseño (PRD §8)

- **Visión computacional.** La evidencia se almacena y se registra su metadata; no se evalúa el daño en la imagen.
- **Gestión de identidades.** El acceso es simulado contra la base sintética; no hay Auth0 ni Google IAM.
- **Otros ramos.** Vida, hogar y gastos médicos quedan fuera.
- **Modelo local.** Ollama está implementado como proveedor intercambiable y documentado como ruta de costo cero, condicionado a disponer de GPU con VRAM suficiente para invocación de herramientas estable.

Limitaciones de la implementación

Estas no vienen del alcance sino de decisiones concretas, y conviene conocerlas antes de extender el sistema:

Limitación	Cuándo se vuelve un problema	Qué hacer entonces
El corpus tiene 19 cláusulas y usa búsqueda exhaustiva.	Con miles de cláusulas la latencia crece linealmente.	Migrar a un índice aproximado (HNSW) y medir la pérdida de recuperación.
La cobertura aludida se detecta con señales léxicas.	Al añadir ramos o coberturas, las palabras clave se vuelven inmanejables.	Resolverlo también con salida estructurada, como el enrutamiento.
La evaluación con el proveedor <code>stub</code> es una línea base.	Siempre: no mide al modelo real.	Correr <code>make eval</code> con credenciales de Anthropic antes de concluir nada.
El historial se resume a los tres expedientes más recientes.	Con un asegurado de cartera antigua, un siniestro relevante de hace años quedaría fuera del contexto.	Seleccionar por relevancia semántica —los del mismo tipo que la consulta— en lugar de por recencia.
El Agente FNOL no consulta el historial.	Al reportar un siniestro recurrente: no puede advertir que ya hay un expediente abierto por el mismo hecho.	Injectarle el mismo resumen que recibe el Agente de Pólizas y añadir una regla de detección de duplicados.

Reproducibilidad

```
pip install -r requirements-dev.txt
cp .env.example .env           # colocar ANTHROPIC_API_KEY
make bootstrap                  # datos sintéticos, historial e índice FAISS
make eval                      # métricas y conversaciones de este reporte
make report                    # regenera este PDF
```

Las versiones están fijadas en `requirements.txt` y la generación de datos sintéticos —cartera e historial de siniestros— es determinista: dos ejecuciones producen la misma base y las mismas credenciales. Las conversaciones del capítulo 4 se capturan contra una base sembrada de cero, así que no dependen del orden en que se corrieron las demás pruebas.

InsurAgent — Prueba de Concepto del ramo de automóviles. Autor: **Diego Carrillo Mondragón**. Documento generado automáticamente por `insuragent.reporting` a partir de la corrida de evaluación registrada en `data/evaluation_report.json`.